

大模型时代下的注意力机制优化综述

史登辉^{1,2}, 奚雪峰^{1,2,3+}, 崔志明^{1,2,3}, 朱 润⁴, 王 坚⁵

1. 苏州科技大学 电子与信息工程学院, 江苏 苏州 215000

2. 苏州市虚拟现实智能交互及应用技术重点实验室, 江苏 苏州 215000

3. 苏州科技大学 智慧城市研究院, 江苏 苏州 215000

4. 昆山市数据局, 江苏 昆山 215301

5. 昆山市公安局, 江苏 昆山 215301

+ 通信作者 E-mail: xfxi@usts.edu.cn

摘 要: 自从注意力机制(attention mechanism)提出后, 基于注意力机制的Transformer架构很快确立了大模型的核心地位, 大语言模型迎来了新的发展方向, 推动了自然语言处理、计算机视觉等众多领域取得了丰厚的成果。近年来, 随着大模型迅猛发展, 模型的参数规模持续增长, 传统的Transformer架构已经难以满足庞大的模型训练要求。除了堆积算力之外, 模型架构的调整以及对于注意力机制的进一步挖掘是解决这一挑战的有效途径, 成为了研究的热点。介绍传统的Transformer架构以及近年来对于Transformer架构及其变体的研究现状, 分析其核心自注意力机制的原理及其面临的瓶颈。分析总结近年来注意力模块的改进, 以DeepSeek为例, 探索其爆火背后基于Transformer的MoE架构和多头潜在注意力机制(multi-head latent attention, MLA)的核心技术路径。总结优化注意力机制的研究现状, 并展望未来研究方向。

关键词: 大语言模型(LLM); 注意力机制; 多头潜在注意力机制(MLA); MoE架构

文献标志码: A **中图分类号:** TP391 **doi:** 10.3778/j.issn.1002-8331.2506-0314

Review of Attention Mechanism in Era of Large Language Models

SHI Denghui^{1,2}, XI Xuefeng^{1,2,3+}, CUI Zhiming^{1,2,3}, ZHU Run⁴, WANG Jian⁵

1. School of Electronic & Information Engineering, Suzhou University of Science and Technology, Suzhou, Jiangsu 215000, China

2. Suzhou Key Laboratory of Virtual Reality Intelligent Interaction and Application Technology, Suzhou, Jiangsu 215000, China

3. Suzhou Smart City Research Institute, Suzhou University of Science and Technology, Suzhou, Jiangsu 215000, China

4. Data Bureau of Kunshan City, Kunshan, Jiangsu 215301, China

5. Public Security Bureau of Kunshan City, Kunshan, Jiangsu 215301, China

Abstract: Since the attention mechanism was proposed, the Transformer architecture based on the attention mechanism has quickly established the core position of large models. The large language model has ushered in a new development direction and promoted fruitful results in many fields such as natural language processing and computer vision. In recent years, with the rapid development of large models, the parameter scale of the model has continued to grow, and the traditional Transformer architecture has been difficult to meet the requirements of large model training. In addition to accumulating computing power, the adjustment of the model architecture and further exploration of the attention mechanism are effective ways to solve this challenge and have become a hot topic of research. This paper first introduces the traditional Transformer architecture and the current status of research on the Transformer architecture and its variants in recent years, and analyzes the principles of its core self-attention mechanism and the bottlenecks it faces. Subsequently, the improvements of the attention module in recent years are analyzed and summarized. Then, taking DeepSeek as an example, the core technical path of the Transformer-based MoE architecture and the multi-head latent attention mechanism (MLA)

基金项目: 国家自然科学基金(62176175, 62372318); 苏州市水利水务科技项目(2025004)。

作者简介: 史登辉(2001—), 男, 硕士研究生, CCF会员, 研究方向为自然语言处理、大模型应用; 奚雪峰(1978—), 男, 博士, 教授, CCF高级会员, 研究方向为自然语言处理、多模态机器学习; 崔志明(1961—), 男, 博士, 教授, CCF高级会员, 研究方向为知识挖掘、机器学习。

收稿日期: 2025-06-26 **修回日期:** 2025-10-28 **文章编号:** 1002-8331(2026)08-0034-14

behind its explosion are explored. Finally, the current status of research on optimizing the attention mechanism is summarized and future research directions are prospected.

Key words: large language model (LLM); attention mechanism; multi-head latent attention mechanism (MLA); MoE architecture

在自然语言处理领域,注意力机制(attention mechanism)是一个突破性进展。注意力机制的起源具有双重理论背景:一方面源于对人类视觉选择性注意机制的仿生学模拟,另一方面则直接产生于神经机器翻译领域对长距离依赖关系建模的迫切需求^[1]。在深度学习发展的早期阶段,循环神经网络(recurrent neural network, RNN)和长短期记忆网络(long short-term memory, LSTM)^[2]是处理序列数据的主流模型,例如机器翻译任务,但是随着序列数据的不断增加,也就是当输入序列变长时,长距离依赖的问题出现了,模型难以记住序列数据中早期出现的信息,表现出遗忘的现象。

Bahdanau 等人^[3]的工作将 Attention 机制首次引入自然语言处理领域,而 2017 年 Google 团队提出的基于自注意力机制的 Transformer 架构^[4]则将 Attention 机制推向了一个新的高潮,引发了 NLP 领域的深刻变革,同时,Transformer 架构及其变体逐渐成为各领域的通用架构。

在 NLP 领域,OpenAI 发布了 GPT (generative pre-trained Transformer),它是单向 Transformer 架构的预训练语言模型^[5],只能从前向后或从后向前依次处理文本,无法同时获取完整的上下文信息,训练数据包含了互联网上大量的文本数据,展现出非常强大的文本生成能力。BERT (bidirectional encoder representations from Transformers)使用双向 Transformer^[6],旨在通过联合调节所有层中的左右上下文来预训练深度双向表示,能够同时捕捉到文本序列中每个词的上下文信息,从而能更准确地理解词语在句子中的含义。

在计算机视觉领域,Transformer 在视觉任务中逐渐取代 CNN^[7],ViT (vision Transformer)用 Transformer 架构替代 CNN,在图像分类任务中表现出更高的准确率,同时,Transformer 模型由于其并行处理能力,在训练和推理速度上也优于 CNN。微软研究院发布了 Swin Transformer^[8],引入层次化窗口注意力,缓解了传统 Transformer 在视觉任务中计算复杂度高和缺乏多尺度建模能力的问题。2024 年,Pinasthika 等人^[9]在 Swin Transformer 的基础上,用 SparTa block 替换了原有的 Swin Transformer block。保留了 Swin Transformer 前三个阶段的分层窗口注意力机制(局部注意力),在第四阶段引入稀疏注意力,结合了局部计算的高效性和稀疏注意力的全局聚焦能力。这种方式既降低了计算成本,又保持了模型对图像关键特征的捕捉能力^[10]。

近年来,多模态大语言模型(multimodal large lan-

guage model, MLLM)作为人工智能领域的前沿研究方向,正持续推动着跨模态智能处理的范式革新。传统方法通常依赖独立编码器处理不同模态数据,这种架构设计不仅限制了模态间的深层交互,还可能导致语义信息的割裂与损失。

2025 年 8 月,OpenAI 推出的 GPT-5 标志着多模态 Transformer 架构的重大突破,其创新的 Universal Transformer 框架通过动态自适应机制实现了多模态数据的深度语义融合与协同计算,为构建更接近人类认知能力的通用人工智能系统提供了新的技术路径。GPT-5 在多模态领域表现卓越,在 MMMU 评估中以 84.2% 准确率创纪录,能综合分析 PPT、音频和文本。在 RoboFlow 测试中,其文档理解和缺陷检测能力突出。其在医疗领域取得的成果尤其突出,GPT-5 整合 3 000 万临床数据,可实时分析影像、报告和病史。约翰霍普金斯医院实验显示,其糖尿病管理方案使血糖达标率提升 28%,且 HealthBench 测试中幻觉率仅 1.6%,显著优于 GPT-4o。

随着模型规模的扩大和应用场景的复杂化,Transformer 及其注意力机制也面临着一系列瓶颈和挑战。Transformer 的自注意力机制时间复杂度为 $O(N^2d)$ ^[11] (N 为序列长度, d 为嵌入维度),当面对长序列问题时,时间复杂度呈平方项增长,同时,对于空间复杂度,主要由中间矩阵的存储需求决定,一般情况下为 $O(N^2)$ 。因此,面对长序列问题时,显存占用也是一大挑战。

本文主要对 Transformer 架构以及其核心注意力机制进行了详细的介绍和探索,分析了注意力计算中的 KV 缓存面临的瓶颈和挑战,并总结了近年来注意力模块优化的主要成果。首先介绍 Transformer 的基本工作流程及其结构;接着对其核心自注意力机制进行了深入的探讨,介绍了注意力机制中的 KV 缓存并探讨了 KV 缓存面临的现状与挑战;整理了近年来注意力模块在计算效率和结构设计两个方面的改进策略;以 DeepSeek 为例,探讨其设计的多头潜在注意力机制在这两个方面的优缺点;最后对大模型时代下注意力机制优化工作的未来研究进行总结与展望。

1 Transformer 架构

在自然语言处理中,文本数据通常以序列的形式出现,例如句子中的单词序列或文档中的句子序列。传统的序列模型,如循环神经网络及其变体(LSTM 和 GRU),通过递归地处理序列中的每个元素来捕捉上下文信息。

然而,这些模型在处理长序列时存在一些问题,如梯度消失和梯度爆炸^[12],导致难以捕捉长距离依赖关系。

此外,RNN的递归结构使得模型无法并行计算,训练效率较低。为了解决传统序列模型的局限性,注意力机制被提出。注意力机制的核心思想是让模型在处理当前元素时,能够动态地关注与当前元素最相关的其他元素。例如,在机器翻译任务中,当翻译一个单词时,模型可以关注原文中与该单词最相关的部分,而不仅仅是前一个单词。这种机制使得模型能够更灵活地捕捉长距离依赖关系,并且提高了模型的表达能力。

Transformer架构正是基于注意力机制的创新。它完全摒弃了传统的递归结构,转而使用自注意力机制(self-attention)来处理序列数据。自注意力机制允许模型在计算每个元素的表示时,同时考虑序列中所有其他元素的信息,从而能够并行处理整个序列,大大提高了计算效率。此外,Transformer还引入了多头注意力机制(multi-head attention),进一步增强了模型对不同子空间信息的捕捉能力。

1.1 Transformer 基本工作流程

Transformer最初在2017年由Vaswani等人^[4]提出时,主要应用于机器翻译任务,如中英文互译,后来研究者发现Transformer的潜力远不止于此,例如,2018年,Google团队提出的BERT采用Transformer的编码器结构进行大规模预训练,并在多项NLP任务(如文本分类、问答系统)上取得突破,同年,OpenAI发布了GPT,基于Transformer的解码器结构,专注于文本生成任务,并逐步发展出GPT-2^[13]、GPT-3^[14]、GPT-5^[15]等更强大的版本,最终催生了ChatGPT等对话式AI。如图1为Transformer执行机器翻译任务时的基本工作流程图,其主体部分由包含了6个block块的Encoder(编码器)和Decoder(解码器)组成。




图1 Transformer 工作流程

Fig.1 Transformer workflow

图1左侧为编码器,右侧为解码器。以翻译英文“Dogs bark”为例,流程如下:编码器首先处理输入文本,生成信息矩阵后传递给解码器。解码器收到起始符

<begin>后,首次推理输出“狗”;随后将“狗”与起始符共同作为输入,继续推理输出“叫”。重复该过程,经多轮迭代后生成完整译文“狗会汪汪叫”。编码器仅需一次前向计算,原语言序列在后续步骤中保持不变。计算流程如图2所示。接下来本文继续讨论Transformer的架构设计。




图2 计算流程图

Fig.2 Calculation flow

1.2 Transformer 架构

Transformer的编码器中堆叠了多个块,其中每个块是模型的一个基本处理单元。每个块包含了多头注意力机制,前馈神经网络(feed forward neural network),残差连接和层归一化(Add&Norm),如图3所示。前馈网络是由两层全连接层和一个非线性激活函数(通常是ReLU)构成。它能对每个位置的特征进行非线性变换,从而增强模型的表达能力。不同位置的特征在经过前馈网络后,会提取出更高级、更抽象的特征,有助于模型学习到输入序列中更复杂的模式和规律。




图3 编码块结构

Fig.3 Encoder block structure

残差连接(residual connection)的作用是解决深层网络训练中的梯度消失和梯度爆炸问题。同时,残差连接也有助于保留输入中的重要信息,防止在网络传递过程中信息丢失。归一化层(normalization layer)一般采用层归一化(layer normalization),它对每个样本的特征进行归一化处理,将特征的均值调整为0,方差调整为1。

归一化可以使模型的训练更加稳定,减少不同特征尺度的影响,加快模型的收敛速度,提高模型的泛化能力。

Transformer的解码器结构与编码器类似,不同的地方是增加了两个组件:掩码多头注意力(masked multi-head attention)与一个残差连接和层归一化,结构图如图4所示。




图4 解码块结构

Fig.4 Decoder block structure

掩码多头注意力^[16]用于处理解码器的输入序列。在生成序列时,为保证模型不会“偷看”未来信息,它会用掩码机制屏蔽后续位置的信息。比如在翻译时,翻译过的单词为1到*i*,当翻译到下一次单词*i*+1时,需要通过mask操作来遮盖住*i*+1之后的单词。通过多头机制,模型能从不同子空间捕捉输入序列的特征,增加了模型的表达能力。通过6个编码块和解码块的堆叠,这就构建了Transformer的编码器与解码器。

2 注意力机制

自2017年Transformer发布以来,就成为NLP领域的“掌上明珠”,深受研究者们的宠爱。而Transformer中最核心的部分是其自注意力机制。

注意力机制是指人类神经系统在面对复杂感知信息时,通过选择性关注(selective attention)和资源分配来优先处理特定刺激的认知过程。该机制使个体能够在大量信息中高效地聚焦于关键刺激、任务或目标^[17]。

注意力调控既可以是自上而下(top-down)的主动过程,如个体基于目标或意图主动选择注意对象;也可以是自下而上(bottom-up)的被动过程,如外界突然的强光刺激^[18]。此外,注意力还表现出动态灵活性,既能够长时间集中于单一任务(持续性注意),也可在不同刺激间快速切换(注意转移)或分配有限资源(注意分配)。

在认知科学中,注意力机制被认为是感知、记忆、决策及行为调控的核心基础。它通过优化信息处理效率,直接影响个体的学习能力、任务表现和适应性行为。神经科学研究进一步表明,前额叶皮层(PFC)、顶叶皮层等

脑区及其协同网络共同参与了注意力的调控与执行^[19]。

值得注意的是,人类注意力的认知与神经机制,为计算建模提供了深刻的生物学启示。受到大脑选择性信息处理方式的启发,研究者尝试在人工神经网络中构建功能类似的计算模块,从而实现了注意力机制在深度学习中的成功应用。其核心思想是通过可学习的权重分配,模拟人脑对关键信息的增强与非关键信息的抑制,以提升模型对重要特征的敏感度。

在深度学习中,注意力机制的核心在于让机器学会去感知数据中的重要和不重要的部分。其模拟的是人类在处理信息的时候,会将自身的注意力放在需要被重点关注的地方,对于其他无关紧要的信息进行筛选过滤。例如,在人脸识别中,本文需要让机器选择性地关注一张图片中人脸的特征,包括耳朵、鼻子、眼睛等等,不需要对一些边缘特征,如背景、轮廓等施加过多的注意力。而在机器翻译任务中,也就是Transformer最开始被设定的任务中,本文需要让机器注意到每个词向量之间的相关性,有侧重地进行翻译,来模拟人类理解的过程。

在Transformer模型中,注意力机制的关键组成部分是查询(query, *Q*)、键(key, *K*)、值(value, *V*)的三元组。本文按照公式计算注意力分数:

Attention(Q, K, V) = softmax(QK^T / sqrt(d_k))V

其中,Transformer采用的是自注意力机制,与交叉注意力(cross-attention)^[20]不同的是, *Q*, *K*, *V* 均来自同一输入序列,即模型计算序列内部元素之间的依赖关系,有助于模型捕捉长距离依赖关系,从而增强上下文的感知能力。交叉注意力机制中的 *Q* 来自一个序列,而 *K* 和 *V* 来自另一个序列,以机器翻译任务为例,当本文将“Dogs bark”翻译为“狗会汪汪叫”时,那么 *Q* 来自序列“狗会汪汪叫”,而 *K* 和 *V* 来自序列“Dogs bark”。其作用是让解码器在生成输出时动态关注编码器的相关信息。两者的核心区别如表1所示。

表1 自注意力与交叉注意力区别			
Table 1 Difference between self-attention and cross-attention			
注意力	输入来源	主要功能	典型应用
自注意力	<i>Q</i> , <i>K</i> , <i>V</i> 均来自同一序列	建模序列内部依赖关系	BERT、GPT 的编码层
交叉注意力	<i>Q</i> 来自序列A, <i>K</i> / <i>V</i> 来自序列B	建模序列间交互关系	Transformer 解码器里接受编码器信息的注意力层

2.1 自注意力机制

随着文本序列长度的爆炸式增长,研究者们曾经面临着拥有海量文本数据却难以进行有效信息的捕捉,自注意力机制的提出彻底改变了这一局限性^[21]。在一段文本序列中,自注意力机制允许输入序列的每个元素都与序列中的其他元素进行注意力分数的计算,使模型能

够聚焦于输入序列中任意不同位置的关系,从而捕捉序列内的长距离复杂依赖关系。自注意力机制结构如图5所示。




图5 自注意力结构图

Fig.5 Self-attention structure diagram

自注意力机制接受的输入是单词序列经过编码后形成的矩阵 X , 或者是上一个 Encoder block 的输出, 而 Q, K, V 正是通过 Self-attention 的输入进行一系列线性变换得到的, 即:

$$X \times W_Q = Q, X \times W_K = K, X \times W_V = V$$

其中, W_Q, W_K, W_V 都是可学习的参数矩阵。

接下来, 进行注意力分数的计算, 本文采用上一节提到的注意力机制的注意力分数计算公式:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

式中, $Q \times K$ 的转置后, 得到一个方阵, 行列数都为 n , 其中 n 为一段文本序列中的单词数, 这个矩阵可以表示 Q 与 K 之间的相似度, 计算所有 Query 和 Key 对的点积:

$$S = QK^T \in \mathbb{R}^{n \times n}$$

这个过程主要是进行了一个点积运算, 进而得到查询与键之间的相关性。

然后进行一个缩放, 为防止点积值过大导致梯度消失, 除以 $\sqrt{d_k}$, d_k 为单词经过编码成为向量之后的维度。接下来进行一个归一化操作, 将得到的注意力分数转化为概率分布:

$$A = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right) \in \mathbb{R}^{n \times n}$$

其中, A_{ij} 表示第 i 个位置的单词对第 j 个位置的单词的注意力权重。用注意力权重 A 对 $Value$ 进行相乘, 得到最终输出:

$$Z = AV \in \mathbb{R}^{n \times d_k}$$

通过上述流程, 模型能够学习序列中不同位置的重要性, 从而捕捉长距离依赖关系。

2.2 多头注意力机制

多头注意力机制在自注意力基础上扩展, 通过并行运行多个自注意力层, 从不同子空间捕捉序列中多样的

语义关联。具体而言, 输入 X 分别经过 h 个独立的 Self-attention 层, 每层具有独立的 Query、Key 和 Value 矩阵, 执行点积运算后得到 h 个输出矩阵。这些输出经拼接和线性融合, 形成最终的注意力向量。该机制使模型能够从多角度分析输入序列, 增强对复杂长距离依赖的建模能力, 结构示意图如图6所示。




图6 多头注意力架构图

Fig.6 Multi-head attention architecture diagram

在多头注意力中, 查询、键和值的线性变换实际上会进行多次, 每个头都有自己的权重矩阵。这样, 输入向量被分割到多个不同的子空间中, 每个子空间执行自注意力操作。由于每个头的计算是独立的, 这些计算可以并行进行, 从而捕捉不同的语义关联, 其次是可以增强模型表达能力, 不同头可以关注不同的特征模式, 如长距离依赖或语法结构, 同时可以优化计算效率, 尽管多头机制增加了参数, 但由于并行计算, 整体计算复杂度与单头注意力相当, 这种并行性使得多头注意力机制在处理长序列数据时更加高效。

可以用一个生活中的例子来理解多头注意力: 想象一个人坐上公交车, 同站还有两人上车; 到下一站, 三人下车、五人上车; 再下一站, 四人下车、两人上车……如此反复, 直到终点站所有人下车。此时若问“公交车一共经过了多少站”, 多数人会不自觉地关注乘客数量的变化, 而忽略问题实际关心的是车站数量。

在这种情况下, 多头注意力机制就能发挥作用: 它可以让一个“注意力头”专门追踪乘客人数, 同时让另一个“注意力头”并行记录经过的车站数。这种多视角并行处理信息的方式, 增强了模型对复杂语义的捕捉与表达能力。

2.3 注意力计算的KV缓存(KVCache)

在自回归生成任务中, 模型会逐个生成 token, 每次生成时都需要处理当前所有已生成的 token。例如, 在 Transformer 解码器的推理阶段, 每次前向传递都会生成一个 token, 将其附加到输入中, 然后将新的输入再次传递回模型进行下一次前向传递, 不断迭代。

然而, 这种朴素的方法显然非常低效, 首先是它重新计算了先前的键、值, 其次是网络中基于每个 token 的其他部分也会再次被使用, 浪费了计算资源。而 KVCache 的核心思想是缓存每一层的 Key 和 Value 矩阵, 在生成

第 t 个 token 时,直接复用前 $t-1$ 个 token 的 KV 值,仅计算当前新 token 的 KV。这样可以将计算复杂度从 $O(n^2)$ 降低到 $O(n)$ (n 是序列长度),减少冗余计算^[22]。这样做的好处是牺牲了部分显存,换取到了不错的推理速度,同时可以减少计算量,在长文本序列的推理计算中尤其明显。

2.4 KV 缓存面临的现状与挑战

在实际工程应用中,注意力机制的 KVCache 会消耗非常多的 GPU 内存,而 GPU 内存恰好是非常稀缺的资源,GPU 的并行处理是本文进行复杂计算时的重要工具,尤其是在当前大模型参数规模庞大,无论是大模型的训练阶段还是推理阶段,都离不开 GPU 算力的支持。现代大语言模型如 GPT-4、Llama 等,其参数规模可达数百亿甚至千亿级别,导致 KV 缓存占用大量显存。

例如,Meta 公司指出,其 Llama 团队开发的 Llama-3.1-8B 在 128 000 上下文长度下,仅单个请求就几乎占满 NVIDIA A100-40 GB GPU 的显存,导致 GPU 利用率不足^[23];OpenAI 宣称 GPT-4 的训练就需要 1 万至 2.5 万张 A100/H100 GPU,推理阶段也需要大量显存支持^[24]。

在实际运算过程中,KV 缓存的应用带来了显著的矛盾现象:相较于内存中待处理的数据规模,单次生成步骤所需执行的矩阵到向量运算规模极小。尽管需要加载庞大的权重矩阵与持续扩展的 KV 缓存,但最终执行的计算任务却十分有限。在现代硬件架构下,数据加载过程消耗的时间远超实际运算耗时,这一现状直接导致 GPU 计算资源无法得到充分利用,计算效率大幅降低。Yuan 等人^[25]在对 LLM 解码阶段的研究中发现,KV 缓存的内存占用会随着批次大小和序列长度线性增长,导致大量的内存占用和流量,这也成为 LLM 解码阶段的主要瓶颈^[25]。

Kimi 公司联合清华大学的 MADSys 实验室,推出了基于 KVCache 的 Mooncake 推理系统设计方案,通过创新的 PD 分离架构和以存换算为中心的理念,显著提升了推理的吞吐能力^[26]。

清华大学与阶跃星辰等机构提出的 MFA 通过在查询-键(Query-Key)中进行低秩矩阵分解,有效地扩展了注意力头的数量和维度,从而增强了模型容量,通过低秩分解和单键值头设计,减少 93.7% 的 KVCache 占用^[27]。

阿里云瑶池旗下云数据库 Tair 面向大语言模型推理场景推出的 KVCache 缓存加速服务 Tair KVCache 通过构建显存-内存-存储三级缓存体系,实现 KVCache 动态分层存储。将 KVCache 由“纯显存驻留”升级为“分级缓存架构”,在提升计算效率的同时显著扩展上下文长度,成为加速 LLM 推理的核心组件。

Moore Threads AI 团队提出了一种新的轮次级注意力机制 Round Attention,它仅调用并计算最相关轮次

的键值缓存。实验表明,他们的方法在不影响模型性能的情况下节省了 55% 的内存使用量^[28]。

3 注意力机制的改进

近年来,随着大模型的迅猛发展,模型的参数规模呈现指数级增长。例如,2023 年 3 月 14 号 OpenAI 发布的 GPT-4 拥有 1 750 亿参数,而 2024 年 12 月 26 日 DeepSeek 发布的 DeepSeek-V3 的参数数量达到了惊人的 6 710 亿。

然而,传统的 Transformer 架构在应对这种超大规模模型训练时逐渐暴露出诸多局限性,如计算复杂度随序列长度呈二次方增长、内存占用过高、长程依赖捕捉效率低下等问题。除了简单地堆积算力资源外,学术界和工业界开始从注意力机制的本质出发,探索更高效的架构创新。

在注意力机制的优化上,目前主要集中于两个方向,一个方向是追求计算效率的优化,目的是降低注意力的计算复杂度,使其能适用于长序列的计算;另一个方向则是探索结构优化,通过改进注意力机制的设计,增强表达能力或泛化能力,在这两个方面目前涌现出以下几类突破性进展:稀疏注意力(sparse attention)通过引入局部敏感哈希(LSH)或滑动窗口等策略,将计算复杂度从 $O(n^2)$ 降至 $O(n \log n)$ ^[29]。Switch Transformer 通过动态路由机制,实现了模型容量的扩展而不显著增加计算开销^[30]。文献[31-32]提出的多查询注意力机制(multi-query-attention, MQA)和分组查询注意力机制(grouped-query-attention, GQA)通过在各个 head 之间共享键和值投影来减少键值缓存的使用。深度求索(DeepSeek)团队提出的多头潜在注意力(multi-head latent attention, MLA)利用低秩键值联合压缩(low-rank key-value joint compression)通过仅缓存潜在向量来降低推理时的 KVCache 开销^[33]。

值得关注的是,这些创新不仅体现在算法层面,还与硬件设计形成了协同进化。例如,Flash attention 通过优化 GPU 内存访问模式,使注意力计算速度提升数倍^[34];而提出的 Ring attention 则通过分布式计算框架,块状计算自注意力和前馈网络,有效解决了传统 Transformer 在处理长序列时面临的内存限制问题。随着对注意力机制认知的不断深入,结合神经科学启发的动态稀疏化、基于物理规律的能量约束等跨学科方法,或将催生出更高效的大模型架构,为 AGI 的发展奠定坚实基础^[35]。

3.1 稀疏注意力(sparse attention)

在计算效率的优化方面,稀疏注意力是注意力机制优化的重要研究成果。从直观上看,当上下文长度达到 10 000 时,并非所有词元之间都存在显著的相关性。研究表明,通过对预训练 Transformer 模型的注意力矩阵进行分析可以发现,这些矩阵通常呈现出明显的稀疏性

特征。例如, Yoon 等人^[36]通过实验观察到, 在使用预训练的 BERT 和 ViT 模型进行微调时, 注意力分数矩阵中大部分元素的值接近于零, 呈现出稀疏分布。

此外, 研究在对多种预训练语言模型(如 GPT、T5)进行训练时发现, 模型的激活稀疏性在训练初期会快速增加, 并在后续训练中保持稳定, 稀疏性比例可达到约 90%^[37]。这些研究结果表明, 预训练 Transformer 模型的注意力矩阵具有显著的稀疏性, 这一特性可以被利用来优化模型的计算效率和性能。基于这些研究结果, 研究者提出了稀疏注意力机制, 其核心思想是通过有选择性地计算部分 Query-Key 对来降低计算复杂度。这种方法能够将计算复杂度从原始注意力机制的二次方 $O(n^2)$ 降低到线性级别 $O(n)$ 。根据实现方式的不同, 稀疏注意力机制主要可以分为两类: 基于位置信息的稀疏化和基于内容的稀疏化方法。

3.1.1 基于位置信息的稀疏化

基于位置的稀疏注意力机制(position-based sparse attention)是 Transformer 模型中对标准自注意力机制的一种优化改进, 旨在降低计算复杂度的同时保持模型的表达能力。基于位置的稀疏注意力根据 token 之间的相对或绝对位置关系来决定注意力模式^[38]。主要包含五种类型: 全局注意力(global attention)、局部块注意力(block local attention)、膨胀注意力(dilated attention)、固定模式注意力(fixed pattern attention)和随机注意力(random attention)。其特征如表 2 所示。

在标准的注意力机制中, 一个输出位置的感受野, 是指在计算该位置输出时, 所有被分配了非零注意力权重的输入位置的集合, 每一个输出位置(例如序列中的第 i 个词)在计算时, 都会与输入序列中的每一个位置(从第 1 个到第 n 个词)进行相似度计算。这意味着, 它的理论感受野是整个输入序列。这是 Transformer 模型强大表达能力的基础, 使其能够捕获序列中任意两个位置之间的长程依赖关系。但在实际处理特定任务时, 注意力权重分布通常是高度稀疏和不均匀的。因此, 一个输出位置的实际有效感受野其实是那些拥有高注意力

权重的输入位置, 而不是整个序列。

3.1.2 基于内容的稀疏化

基于内容的稀疏化是指根据输入序列中各个元素的内容特征, 动态地选择最相关的元素进行注意力计算, 而不是对所有元素进行全连接的计算。

主要方法之一是 Routing Transformer。Routing Transformer 通过聚类的方式实现基于内容的稀疏化: 首先将查询(Query)和键(Key)投影到同一空间, 接着使用 k -means 聚类将查询和键分配到不同的聚类中心, 这样处理之后每个查询只与同一聚类中心的键进行计算^[39]。

第二种方法是 Reformer。Reformer 是一种基于 Transformer 架构的模型, 其使用局部敏感哈希(locality-sensitive hashing attention, LSH)实现基于内容的稀疏化: 通过对查询和键使用相同的投影矩阵, 应用 LSH 函数将相似的查询和键分配到相同的 Bucket 中, 其中每个查询只与同桶内的键进行计算。由于不需要存储和计算所有的注意力权重, LSH 注意力大大减少了模型在训练和推理过程中的内存占用。这使得 Reformer 可以在有限的硬件资源下处理更长的序列, 或者在相同的资源下提高训练和推理的速度^[40]。

本文还可以采用 SAC(sparse adaptive connection)方法, 它结合了基于内容和基于位置的稀疏化: 首先选择固定数量的最近邻(基于位置), 然后根据查询与键的相似度选择最相关的键(基于内容)。SAC 方法结合了基于内容和基于位置的稀疏化。它将输入序列视为图, 通过强化学习训练边预测器来基于内容相似性确定节点间的连接, 实现基于内容的稀疏化, 比如在处理文本时会让模型学习关键内容间的联系并建立注意力边。同时, SAC 也隐式考虑位置信息, 结合内容自适应地在位置相近节点间建立连接, 利用数据位置特性优化注意力计算。通过这种结合, SAC 能更灵活自适应地构建注意力图, 高效捕捉关键信息, 减少计算量, 提升模型性能和效率^[41]。

表 2 基于位置的稀疏注意力机制类型

Table 2 Position-based sparse attention mechanism type

稀疏注意力类型	核心思想	优点	缺点
Global attention	结合全局注意力(部分关键位置)和局部滑动窗口注意力	平衡长程和短程依赖, 实现可控稀疏化	全局关键点选择可能忽略重要信息
Block local attention	将序列划分为固定块, 每个块内全连接, 块间稀疏连接	降低计算复杂度, 保留局部信息	长程依赖需多层传递, 可能丢失全局信息
Dilated attention	类似空洞卷积, 在滑动窗口中引入间隔, 跳过一些 token	在保持窗口内计算量不变的前提下, 极大地扩大了感受野, 能更高效地捕获长程依赖关系	间隔可能遗漏关键局部信息
Fixed pattern attention	预定义固定注意力范围(如仅关注前 n 个位置)	简单高效, 适合缓存优化	难以适应动态依赖关系
Random attention	随机选择固定数量的位置进行注意力计算	理论均匀覆盖, 适合近似全注意力	随机性可能导致不稳定训练

3.2 多查询/分组查询注意力

在注意力机制的结构优化方面,多查询注意力(MQA)和分组查询注意力(GQA)是Transformer架构中多头注意力(multi-head attention,MHA)的两种重要改进形式。这些创新性设计显著提升了解码器在推理阶段的效率^[42],因而被广泛应用于 Llama2^[43]、Chat-GLM^[44]等大型语言模型中。三者的对比图如图7所示。

多查询注意力机制最早于2019年提出,其初衷是解决Transformer在增量推理过程中效率低下的问题。然而在当时,这一技术并未引起足够重视。随着Transformer架构和GPT模型逐渐成为生成式大模型的基座技术,特别是在产业落地过程中面临的实际性能挑战,使得GPT模型的推理加速问题备受关注,MQA技术也因此重新获得业界青睐。作为对MQA的进一步发展和完善,分组查询注意力于2023年被提出。GQA采用了一种介于MQA和传统MHA之间的折中方案:通过将查询头分组处理,既保留了MHA的部分表达能力,又继承了MQA的高效推理特性。这种平衡设计使其在模型预测性能和推理效率之间取得了理想的权衡,因而成为当前大模型架构设计中的重要选择。

在多查询注意力(MQA)的设计中,其与标准多头注意力(MHA)的关键区别在于参数共享机制。传统的MHA中,每个注意力头都独立维护着自己专属的Key、Query和Value矩阵参数。而MQA对此进行了创新性优化:首先,MQA保留了每个注意力头独有的Query矩阵,确保模型仍能捕捉多样化的注意力模式。然而,它将原本分散在各个头中的Key和Value矩阵统一为全局共享参数,即整个注意力层仅维护一组共享的Key矩阵和一组共享的Value矩阵,所有注意力头共同复用这两组参数。

这一设计的优势显而易见:通过大幅减少Key和Value矩阵的冗余参数,MQA显著降低了模型的存储开销和计算复杂度。同时,由于Query矩阵仍保持独立,模型在注意力多样性方面的表达能力并未受到明显影响。简言之,MQA通过参数共享实现了效率提升,而其核心思路正是将Key和Value参数从各个头中抽离,转

为全局共享,仅保留Query参数的分头独立性。

可想而知,MQA这种方式虽然大幅减小了参数数量,从而实现了推理加速,但是,这种方法在提升效率的同时也带来了明显的模型性能下降,为了权衡计算效率与模型性能,研究者提出了GQA机制,其核心思想是将查询头分成若干组,每组内部共享一组键和值。这种设计在保持较低计算开销的同时,有效缓解了MQA带来的性能损失问题。最近,Chen等人^[45]基于GQA提出了AsymGQA,这是一种基于激活机制的方法,可以非对称地将MHA分组到GQA,从而获得更好的模型性能,大大缓解了GQA在模型性能和硬件效率之间的权衡问题。

2024年12月,DeepSeek团队推出的DeepSeek-V3模型提出了多头潜在注意力机制(MLA),这一架构通过低秩键值联合压缩技术(low-rank key-value joint compression)显著降低了推理过程中的KV缓存开销,在模型性能优于传统多头注意力的同时,实现了更高的计算效率。此外,该模型将前馈网络改造为DeepSeek-MoE结构——一种对传统混合专家系统(mixture of experts)的优化改进,进一步提升了模型的表达能力与计算效能。接下来将介绍DeepSeek的架构创新。

3.3 MLA——DeepSeek对注意力机制的创造性优化

2025年伊始,国产开源混合专家系统(mixture of experts, MoE)架构大语言模型DeepSeek-V3在全球AI领域掀起巨大浪潮。凭借革命性的训练成本优化,该模型迅速登顶开源大模型性能榜首,不仅超越了同属开源阵营的Llama 3.1和Qwen2.5等竞争对手,甚至在多项基准测试中比肩甚至超越闭源商业巨头Anthropic的Claude 3.5和OpenAI的GPT-4o。在AI行业普遍面临训练成本飙升的背景下,DeepSeek-V3的出现堪称一场效率革命。作为对比,Meta训练其旗舰开源模型Llama 3.1-405B时,动用了超过16 000块NVIDIA H100 GPU,总训练成本估计高达6.4亿美元^[46]。而DeepSeek-V3仅以557万美元的训练成本,就实现了与之匹敌甚至更优的性能表现。这一惊人的成本效益比,主要得益于




图7 MHA、GQA、MQA对比图

Fig.7 Comparison diagram of MHA,GQA and MQA

DeepSeek团队在模型架构和训练方法上的多项创新。

例如,其创造性地提出多头潜在注意力(MLA)机制,通过压缩和扩展潜在特征,优化KV缓存,提升推理效率。其采用FP8混合精度训练,通过训练过程中动态选择不同精度的数据类型,以平衡计算效率和模型精度。然后是优化的MoE架构,通过部分激活给定任务所需的特定专家,而不是激活整个神经网络,从而降低计算消耗。MoE架构通常包含路由专家(routed experts)和共享专家(shared experts)这两种。其中,routed experts通过路由机制动态处理输入,而shared experts提供通用处理能力,两者结合使MoE能够处理复杂任务,同时保持计算效率。

此外,DeepSeek-V3还使用了多token预测(MTP)、DualPipe跨节点通信、无辅助损失负载均衡、跨节点通信优化等技术加速模型训练与推理。其技术创新总结如表3所示。

DeepSeek作为一种思索与搜索的工具,以其算力自主和算法优化能力,极大降低模型的能源与计算成本,实现“低成本+高性能”双重突破,表明大模型的天价成本并非必然,算力垄断也并非牢不可破^[47]。通过算法创新和系统优化,完全可以突破“大模型必须依赖天价算力”的行业困境。这一突破不仅为资源有限的研究机构提供了可行性路径,更可能重塑全球AI产业的竞争格局。正如业内人士所言,DeepSeek-V3的出现标志着“算法效率的革命正在超越单纯算力堆砌的时代”。

3.4 混合专家模型

近年来,深度学习技术在计算机视觉、自然语言处理、科学计算等多个领域取得了突破性进展,展现出强大的应用潜力。然而,随着技术应用的不断深化和场景的持续拓展,现有模型在复杂任务中的表现仍面临诸多挑战:一方面,现实应用场景对模型的泛化能力、推理效率和计算成本提出了更高要求;另一方面,工业界和学术界对模型性能边界的探索需求日益迫切,亟需更具突破性的技术创新来推动人工智能能力的跃升。

扩展模型参数规模是增强模型容量,提高模型能力最简单、最有效的方式之一^[48]。因此,近年来大模型的参数规模呈现爆炸性增长趋势。如发布的T5^[49]还仅有

110亿个参数,但之后发布的GPT-3参数量就达到了1750亿,随后的Gopher^[50]参数量更是继续增长到2800亿规模,而2023年的PaLM^[51]参数量已经达到惊人的5400亿。传统稠密模型,几乎所有参数都参与计算,计算成本随着模型参数规模增长线性增加。持续增长的模型参数为模型训练和推理的计算开销带来严峻挑战,严重阻碍了模型规模的进一步扩展,迫切需要新的模型架构解决这一挑战。

混合专家系统(MoE)作为突破当前深度学习发展瓶颈的重要方法之一,其理论雏形早在文献[52]中被提出,旨在利用分治策略将复杂问题分解为多个子问题进行求解。该架构创新性地将复杂建模任务分解为多个专业化子任务,通过动态路由机制实现任务的并行求解。MoE的核心设计包含两大关键要素:首先,将传统单体模型解耦为一组规模精简的专家子网络;其次,引入可微分门控机制实现输入样本的智能路由。与传统集成学习方法中所有子模块必须参与每个样本处理不同,MoE通过任务感知的专家选择机制,使每个专家网络能够专注于其最擅长的输入特征空间,实现真正的专业化分工。特别值得注意的是,MoE采用专家稀疏激活策略,在仅需次线性增加计算开销的情况下,即可显著提升模型的表征能力和任务性能,这种计算效率与模型容量的平衡优化使其成为大规模模型设计的理想选择。DeepSeek采用的MoE架构如图8所示。




图8 DeepSeek-MoE 架构

Fig.8 DeepSeek-MoE architecture

表3 DeepSeek 技术创新总结

Table 3 Summary of DeepSeek's technical innovations

技术创新	训练效率	推理效率	部署友好性
MLA 架构优化	提升计算并行性	降低延迟	适配不同硬件
Key/Value 低秩压缩	减少显存占用	降低KV 缓存	减少存储需求
Query 低秩压缩	略微影响训练速度	加速注意力计算	需适配低秩推理
无辅助损失负载均衡策略	稳定训练收敛	—	—
多token 预测(MTP)	提升训练吞吐	可能增加推理复杂度	须优化推理逻辑
FP8 混合精度训练	加速训练	FP8 推理需硬件支持	依赖FP8 硬件
DualPipe 算法	优化流水线并行	—	需兼容分布式部署
跨节点通信优化	加速多机训练	—	需优化网络配置

MoE模型的输出格式如下:

$$y = \sum_{i=1}^n G(x) E_i(x)$$

其中, $E_i(x)$ 表示专家 i 对输入 x 的输出, $G(x)$ 表示门控网络对输入 x 的输出。当使用 Top- k [53] 门控网络时, 门控网络从 n 个专家中选择 k 个专家处理输入样本。Softmax 函数被广泛应于门控网络, 门控网络的输出如下所示:

$$G(x) = \text{softmax}(\text{Top-}k(xW_{\text{gate}}, k))$$

其中, W_{gate} 为门控网络参数。使用 Top- k 操作保留门控输出的前 k 个值, 并设置其余专家输出为负无穷, 从而通过 Softmax 只评估前 k 个专家。

MoE 目前已经广泛应用于计算机视觉 [54-57]、多模态 [58-60]、语音识别 [61-63] 以及推荐搜索系统 [64-65] 等众多 AI 细分领域, 并取得巨大成功。特别是在自然语言处理领域 [66-69], MoE 已经成为大模型降低计算成本的有效解决方案之一。采用 MoE 架构的 GLaM [70] 具有最多 1.2×10^{12} 参数, 虽然参数规模是 GPT-3 的 7 倍, 但计算量只有其 1/3, 并在 29 个自然语言处理基准任务上取得了超越 GPT-3 的表现。其他大模型如 2025 年 5 月 14 日阿里发布的 Qwen3, 其技术报告指出, Qwen3 的 MoE 结构中仅包含 235×10^9 参数, 同期 DeepSeek 的总参数量为 671×10^9 ; Qwen3 推理时的激活参数为 22×10^9 , 而 DeepSeek 的激活参数为 37×10^9 。从中可以看出未来 MoE 的发展趋势是往轻量化, 低参数量发展。MoE 大模型的不断涌现不仅推动了大模型的快速发展, 也加速了生成式人工智能 (AIGC) 领域的研究进程。然而, 专家稀疏激活特性是把双刃剑, 既有益于降低模型计算开销, 提升模型专业能力, 又对模型的高可扩展和高效性带来极大挑战 [71]。

3.5 多头潜在注意力机制

MLA 是一种改进的注意力机制, 结合了多头注意力和潜在变量建模的思想, 旨在更高效地捕捉输入数据中的复杂依赖关系。早在 DeepSeek-V2 的技术报告中就已经提出 MLA 机制 [72], 如图 9 所示。并对其核心低秩联合压缩 K 、 V 来减少 KVCache 进行了系统的阐述,




图9 MLA 机制

Fig.9 Multi-head latent attention (MLA) mechanism

首先进行 Key 和 Value 潜在向量的压缩:

$$c_t^{\text{KV}} = W^{\text{DKV}} h_t$$

其中, $c_t^{\text{KV}} \in \mathbb{R}^d$, 代表第 t 个 token 的键值压缩潜在向量, d 代表模型的隐藏维度, d_c 表示 KV 压缩维度, 满足 $d_c \ll d_h n_h$, d_h 代表每个注意力头的维度, n_h 代表注意力头的数量。 $W^{\text{DKV}} \in \mathbb{R}^{d_c \times d}$ 表示下投影矩阵, $h_t \in \mathbb{R}^d$ 代表给定注意层中第 t 个 token 的注意力输入。

接着, 通过降维矩阵生成 Key 和 Value:

$$k_t^C = W^{\text{UK}} c_t^{\text{KV}}$$

$$v_t^C = W^{\text{UV}} c_t^{\text{KV}}$$

通过两个上投影矩阵 W^{UK} 和 W^{UV} , 用于将 U 相关的特征映射到生成“Key”和“Value”的空间。然后, 加入旋转位置编码生成最终的 Key。

$$k_t^R = \text{RoPE}(W^{\text{KR}} h_t)$$

这个公式描述了键向量 (Key) 的旋转位置编码 (RoPE) 生成过程, 这是为了在注意力机制中显式引入位置信息, 其中 h_t 是时间步 t 的输入隐藏状态, W^{KR} 是用于生成携带旋转位置嵌入的解耦键的矩阵。 $\text{RoPE}(\cdot)$ 表示旋转位置编码 (rotary positional embedding), 是一种动态位置编码方法 [73]。

最终, 进行拼接后, 得到的 Key 的表示为:

$$k_{t,i} = [k_{t,i}^C; k_{t,i}^R]$$

其中, $k_{t,i}$ 是第 t 个位置, 第 i 个相关的“Key”向量。

随着 DeepSeek 提出的 MLA 机制在计算效率上的显著优势 (如 KVCache 显存降低 93.3%, 推理速度提升 3.2 倍), 传统基于多头注意力 (MHA) 及其变体的大语言模型在训练成本、推理延迟、长序列处理等方面逐渐显现出竞争劣势。

然而, 由于当前主流开源模型均采用 MHA/GQA 架构, 若要让这些预训练模型适配 MLA 机制, 传统方法需完全重新预训练, 导致极高的计算成本。

为解决这一问题, 来自复旦大学 NLP 实验室、华东师范大学等机构的研究团队提出了 MHA2MLA 框架, 其核心目标是在最小化训练开销的前提下, 将现有 MHA 模型高效迁移至 MLA 架构。该框架能够最大限度地重用预训练 MHA 网络的参数, 同时将键值缓存存储和推理过程与 MLA 范式保持一致 [74], 为在不牺牲性能的情况下部署高效资源的 LLM 提供了一条切实可行的途径。

MLA 是近年来注意力机制优化的重大突破, 其核心优势在于显著降低 KV 缓存显存占用, 同时保持模型性能。

传统 Transformer 的 MHA 需要存储完整的键值对, 显存消耗随序列长度线性增长, 而 MLA 通过低秩分解将 KV 矩阵压缩为少量潜在向量, 减少 90% 以上的显存需求, 使模型能高效处理超长文本。此外, MLA 具备出

色的迁移适配性,仅需极少量数据微调(0.3%~0.6%原始训练量)即可将现有MHA/GQA模型转换为MLA架构,几乎无损性能。

在计算效率上,MLA通过共享潜在键值降低FLOPs,推理速度提升20%~50%,尤其适合长序列任务。其设计兼容现有Transformer框架,可无缝集成至MoE等混合架构,为低成本部署和长上下文建模提供解决方案。

相比稀疏注意力或线性近似方法^[75],MLA在压缩率、计算效率和实用性上更均衡,推动大语言模型向轻量化、长文本方向演进。

表4对比了MLA与稀疏注意力、多查询/分组查询注意力的几个关键维度。

4 总结与展望

近年来,注意力机制的优化研究已成为提升大规模语言模型计算效率的关键技术方向。该领域呈现出显著的矛盾性特征:从计算复杂性角度分析,传统注意力机制(如标准Transformer架构中的多头注意力模块)因其固有的 $O(N^2)$ 时间复杂度特性,以及随序列长度线性增长的显存占用问题,在长序列处理任务中面临严峻的可扩展性挑战。实证研究表明,当处理超过32 000 tokens的序列时,传统注意力机制的计算开销和显存需求会呈现平方级增长态势,这严重限制了其在长文本理解、基因组分析等实际应用场景中的部署可行性。与此同时,现有的各类优化方法在试图降低计算资源消耗的过程中,又不可避免地引入了新的技术难题。例如,稀疏注意力机制虽然通过局部窗口或随机采样策略将计算复杂度降低至接近线性水平,但其在长程依赖建模能力方面存在明显缺陷;低秩近似方法尽管能有效压缩显存占用,却面临着近似误差累积导致模型性能下降的问题。针对当前面临的挑战,未来可能会有以下值得深入探索的研究方向。

(1)长程依赖建模能力的优化。针对当前稀疏注意力机制在长程依赖建模方面的局限性,未来研究将重点关注层次化注意力架构的创新。例如,Filipek^[76]提出的SQA(sparse query attention)通过减少查询头数量直接降低注意力计算的FLOPs,在长序列(32 000~200 000 tokens)处理中可实现高达3倍的吞吐量提升。通过构建多粒度的注意力机制,可望实现局部细粒度特征与全局语义信息的有效融合。具体而言,可采用金字塔式注意力结构,底层处理局部窗口信息,高层建模全局依赖关系。同时,引入动态路由机制^[77],使模型能够自适应地选择不同层次的注意力模式。基于图神经网络的注意力扩展也是重要方向^[78],通过将序列数据转化为图结构,利用图注意力网络(GAT)的特性来增强远距离元素间的信息传递。

(2)近似误差累积问题。为缓解低秩近似方法带来的误差累积效应,马里兰大学帕克分校计算机科学系的研究者提出了Loki,一种新型稀疏注意力方法,对于每一个新生成的Query,Loki都会重新在低维空间中对所有候选KV进行一次快速评估和排序^[79]。这个过程是动态和自适应的,能够根据当前上下文的需要,精准地挑选出最相关的令牌集合,从而在每个生成步骤都最大限度地减少近似误差。

未来研究将沿着三个路径展开:首先,开发误差补偿机制,通过引入残差注意力路径来修正近似计算产生的偏差^[80];其次,研究混合精度注意力计算,对关键注意力头采用全精度计算,非关键部分使用低秩近似^[81];最后,探索基于蒙特卡洛采样的随机注意力验证方法^[82],动态评估近似误差并相应调整计算策略。

(3)模型架构的深度融合与统一。MoE与其他核心架构的深度融合将释放更大潜力。例如,探究MLA与MoE的协同设计,能够提升模型理解复杂依赖关系的能力。正如Mu等人所展望^[83],这种多技术路径的交

表4 MLA与稀疏、多查询/分组查询注意力对比

Table 4 Comparison of multi-head latent attention, sparse attention and multi-query/grouped query attention

维度	稀疏注意力	多查询/分组查询注意力	多头潜在注意力
核心理念	在传统全注意力机制的基础上,通过主动筛选关键token、过滤无关token来优化注意力分配,从而在保证模型性能的同时,大幅降低计算复杂度与内存消耗	差异化设计Query矩阵、共享Key与Value矩阵的参数分配策略,在不显著损失模型表达能力的前提下,大幅降低计算与内存开销,保留查询头的独立性,同时精简KV的冗余消耗	通过对注意力机制中的Key(键)和Value(值)矩阵进行低秩联合压缩,在保留核心语义信息的前提下,大幅减少推理过程中需要缓存的KV键值对数量,从而突破长文本处理时的内存瓶颈,同时维持模型对复杂语义关系的捕捉能力
KVCache优化	按稀疏模式裁剪	共享单组KV/分组共享KV	投影压缩结合恒等变换
目标	在计算效率上降低KV缓存的内存利用率,最大限度地减少推理延迟,并提高大语言模型的整体吞吐量。在结构上,聚焦关键token、过滤无关token,将注意力计算从全量交互转为局部或针对性关联,保留核心语义信息处理能力	在计算效率上,通过共享Key和Value矩阵减少参数与缓存开销,在保证模型性能基本不受损的前提下,大幅提升长上下文推理的速度并降低内存占用。在结构设计上通过差异化复用Key和Value矩阵,保留Query多头多视角语义捕捉能力	在计算效率上,通过将原始高维输入序列投影到一个固定长度的低维“潜在空间”中,来显著降低计算注意力时的时间与空间复杂度,从而实现超长序列的高效处理;在结构上结合GQA的分组思想,但引入更灵活的层级共享。部分头处理局部特征(共享KV),部分头处理全局特征(独立KV)

叉与融合,有望催生下一代高效、强大且专精化的大模型架构。

参考文献:

- [1] MNIH V, HEES N, GRAVES A, et al. Recurrent models of visual attention[C]//Advances in Neural Information Processing Systems 27, 2014: 2204-2212.
- [2] GRAVES A. Long short-term memory[M]//Supervised sequence labelling with recurrent neural networks. Berlin, Heidelberg: Springer, 2012: 37-45.
- [3] BAHDANAU D, CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate[EB/OL]. [2025-05-07]. <https://arxiv.org/abs/1409.0473>.
- [4] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30, 2017: 5998-6008.
- [5] YAO C W, CAI D, BU J J, et al. Pre-training the deep generative models with adaptive hyperparameter optimization[J]. Neurocomputing, 2017, 247: 144-155.
- [6] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding [C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019: 4171-4186.
- [7] WANG Y L, DENG Y J, ZHENG Y J, et al. Vision transformers for image classification: a comparative survey[J]. Technologies, 2025, 13(1): 32.
- [8] LIU Z, LIN Y T, CAO Y, et al. Swin transformer: hierarchical vision Transformer using shifted windows[C]//Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2022: 9992-10002.
- [9] PINASTHIKA K, LAKSONO B S P, IRSAL R B P, et al. SparseSwin: swin Transformer with sparse Transformer block [J]. Neurocomputing, 2024, 580: 127433.
- [10] LIU H T, LI C Y, WU Q Y, et al. Visual instruction tuning [C]//Advances in Neural Information Processing Systems 36, 2023: 34892-34916.
- [11] KELES F D, WIJEWARDENA P M, HEGDE C. On the computational complexity of self-attention[C]//Proceedings of the 34th International Conference on Algorithmic Learning Theory, 2023: 597-619.
- [12] BENGIO Y, SIMARD P, FRASCONI P. Learning long-term dependencies with gradient descent is difficult[J]. IEEE Transactions on Neural Networks, 1994, 5(2): 157-166.
- [13] RADFORD A, WU J, CHILD R, et al. Language models are unsupervised multitask learners[J]. OpenAI Blog, 2019, 1(8): 9.
- [14] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems 33, 2020: 1877-1901.
- [15] WANG S S, HU M Z, LI Q, et al. Capabilities of GPT-5 on multimodal medical reasoning[EB/OL]. [2025-05-09]. <https://arxiv.org/abs/2508.08224>.
- [16] NICOLSON A, PALIWAL K K. Masked multi-head self-attention for causal speech enhancement[J]. Speech Communication, 2020, 125: 80-96.
- [17] LU Z L. Mechanisms of attention: psychophysics, cognitive psychology, and cognitive neuroscience[J]. The Japanese Journal of Psychonomic Science, 2008, 27(1): 38-45.
- [18] CORBETTA M, SHULMAN G L. Control of goal-directed and stimulus-driven attention in the brain[J]. Nature Reviews Neuroscience, 2002, 3(3): 201-215.
- [19] PETERSEN S E, POSNER M I. The attention system of the human brain: 20 years after[J]. Annual Review of Neuroscience, 2012, 35: 73-89.
- [20] DU Y Z, CHEN X, FU Y Q. Multiscale transformers and multi-attention mechanism networks for pathological nuclei segmentation[J]. Scientific Reports, 2025, 15: 12549.
- [21] DEGUCHI H, TAMURA A, NINOMIYA T. Dependency-based self-attention for Transformer NMT[C]//Proceedings of the International Conference on Recent Advances in Natural Language Processing, 2019: 239-246.
- [22] HE Y F, LIU J, WU W J, et al. ZipCache: accurate and efficient KV cache quantization with salient token identification [C]//Advances in Neural Information Processing Systems 37, 2024: 68287-68307.
- [23] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The Llama 3 herd of models[EB/OL]. [2025-05-12]. <https://arxiv.org/abs/2407.21783>.
- [24] OPENAI, ACHIAM J, ADLER S, et al. GPT-4 technical report [EB/OL]. [2025-05-12]. <https://arxiv.org/abs/2303.08774>.
- [25] YUAN Z H, SHANG Y Z, ZHOU Y, et al. LLM inference unveiled: survey and roofline model insights[EB/OL]. [2025-05-12]. <https://arxiv.org/abs/2402.16363>.
- [26] QIN R Y, LI Z M, HE W R, et al. Mooncake: a KVCache-centric disaggregated architecture for LLM serving[EB/OL]. [2025-05-13]. <https://arxiv.org/abs/2407.00079>.
- [27] HU J C, LI H Y, ZHANG Y M, et al. Multi-matrix factorization attention[EB/OL]. [2025-05-13]. <https://arxiv.org/abs/2412.19255>.
- [28] TANG Y H, HU Z C, CHENG K, et al. Round attention: a novel round-level attention mechanism to accelerate LLM inference[EB/OL]. [2025-05-14]. <https://arxiv.org/abs/2502.15294>.
- [29] FU T Y, HUANG H F, NING X F, et al. MoA: mixture of sparse attention for automatic large language model compression[EB/OL]. [2025-05-14]. <https://arxiv.org/abs/2406.14909>.
- [30] FEDUS W, ZOPH B, SHAZEER N. Switch Transformers: scaling to trillion parameter models with simple and effi-

- cient sparsity[J].2022, 23(1): 5232-5270.
- [31] AINSLIE J, LEE-THORP J, DE JONG M, et al. GQA: training generalized multi-query Transformer models from multi-head checkpoints[EB/OL].[2025-05-14].<https://arxiv.org/abs/2305.13245>.
- [32] SHAZEER N. Fast Transformer decoding: one write-head is all you need[EB/OL].[2025-05-18].<https://arxiv.org/abs/1911.02150>.
- [33] LIU A X, FENG B, XUE B, et al. DeepSeek-V3 technical report[EB/OL].[2025-05-18].<https://arxiv.org/abs/2412.19437>.
- [34] DAO T, FU D Y, ERMON S, et al. FlashAttention: fast and memory-efficient exact attention with IO-awareness[EB/OL].[2025-05-18].<https://arxiv.org/abs/2205.14135>.
- [35] LIU H, ZAHARIA M, ABBEEL P. Ring attention with blockwise Transformers for near-infinite context[EB/OL].[2025-05-19].<https://arxiv.org/abs/2310.01889>.
- [36] YOON B, LEE A H, KIM J, et al. Exploring attention sparsity to accelerate transformer training on GPUs[J]. IEEE Access, 2024, 12: 131373-131384.
- [37] ZHANG Z Y, XIAO C J, QIN Q, et al. Exploring the benefit of activation sparsity in pre-training[EB/OL].[2025-05-20].<https://arxiv.org/abs/2410.03440>.
- [38] BULATOV A, KURATOV Y, KAPUSHEV Y, et al. Beyond attention: breaking the limits of Transformer context length with recurrent memory[C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence, 2024: 17700-17708.
- [39] HUANG J H, BAO Y W. Rethinking transformers for efficiency and scalability[J]. Available at SSRN 5161897, 2025.
- [40] MIJWIL M M, KAPAYA S. Global adoption of artificial intelligence[J]. Innovations in Optimization and Machine Learning, 2025: 399.
- [41] LI X Y, MENG Y X, ZHOU M X, et al. SAC: accelerating and structuring self-attention via sparse adaptive connection [C]//Advances in Neural Information Processing Systems 33, 2020: 16997-17008.
- [42] ARAR M, SHAMIR A, BERMANO A H. Learned queries for efficient local attention[C]//Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 10831-10842.
- [43] TOUVRON H, MARTIN L, STONE K, et al. Llama 2: open foundation and fine-tuned chat models[EB/OL].[2025-05-22].<https://arxiv.org/abs/2307.09288>.
- [44] GLM T, XU B, ZENG A H, et al. ChatGLM: a family of large language models from GLM-130B to GLM-4 all tools [EB/OL].[2025-05-22].<https://arxiv.org/abs/2406.12793>.
- [45] CHEN Y A, ZHANG C, GAO X T, et al. Optimised grouped-query attention mechanism for Transformers[EB/OL].[2025-05-23].<https://arxiv.org/abs/2406.14963>.
- [46] DERROY A, MAITY S. Code generation and algorithmic problem solving using llama 3.1 405B[EB/OL].[2025-05-24].<https://arxiv.org/abs/2409.19027>.
- [47] 曾建勋. DeepSeek 开源的力量[J]. 农业图书情报学报, 2025, 37(2): 100-101.
- ZENG J X. The power of DeepSeek open source[J]. Journal of Library and Information Science in Agriculture, 2025, 37(2): 100-101.
- [48] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models[EB/OL].[2025-05-25].<https://arxiv.org/abs/2001.08361>.
- [49] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2020, 21(140): 1-67.
- [50] RAE J W, BERGEAUD S, CAI T, et al. Scaling language models: methods, analysis & insights from training gopher [EB/OL].[2025-05-25].<https://arxiv.org/abs/2112.11446>.
- [51] CHOWDHERY A, NARANG S, DEVLIN J, et al. PaLM: scaling language modeling with pathways[J]. Journal of Machine Learning Research, 2023, 24(240): 1-113.
- [52] JACOBS R A, JORDAN M I, NOWLAN S J, et al. Adaptive mixtures of local experts[J]. Neural Computation, 1991, 3(1): 79-87.
- [53] SHAZEER N, MIRHOSEINI A, MAZIARZ K, et al. Outrageously large neural networks: the sparsely-gated mixture-of-experts layer[EB/OL].[2025-05-26].<https://arxiv.org/abs/1701.06538>.
- [54] KONG R, LI Y C, WANG W J, et al. Serving MoE models on resource-constrained edge devices via dynamic expert swapping[J]. IEEE Transactions on Computers, 2025, 74(8): 2799-2811.
- [55] FAN Z W, SARKAR R, JIANG Z Y, et al. M³ViT: mixture-of-experts vision Transformer for efficient multi-task learning with model accelerator co-design[C]//Proceedings of the 36th International Conference on Neural Information Processing Systems, 2022: 28441-28457.
- [56] LI B, SHEN Y F, YANG J K, et al. Sparse mixture-of-experts are domain generalizable learners[EB/OL].[2025-05-27].<https://arxiv.org/abs/2206.04046>.
- [57] XUE F Z, SHI Z J, WEI F T, et al. Go wider instead of deeper [C]//Proceedings of the 36th AAAI Conference on Artificial Intelligence, 2022: 8779-8787.
- [58] LIANG W X, YU L L, LUO L, et al. Mixture-of-Transformers: a sparse and scalable architecture for multi-modal foundation models[EB/OL].[2025-05-29].<https://arxiv.org/abs/2411.04996>.
- [59] DAI Y, TANG D Y, LIU L X, et al. One model, multiple modalities: a sparsely activated approach for text, sound, image, video and code[EB/OL].[2025-05-29].<https://arxiv.org/abs/2205.06126>.
- [60] MUSTAFA B, RIQUELME C, PUIGCERVER J, et al. Mul-

- timodal contrastive learning with LIMoE: the language-image mixture of experts[C]//Advances in Neural Information Processing Systems 35, 2022: 9564-9576.
- [61] MONDAL A, ANIRUDH R, SELVARAJ P. Multitask deep learning for the emulation and calibration of an agent-based malaria transmission model[J]. PLoS Computational Biology, 2025, 21(7): e1013330.
- [62] PAN X L, LIN W X, ZHANG L, et al. FSMoE: a flexible and scalable training system for sparse mixture-of-experts models[C]//Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems. New York: ACM, 2025: 524-539.
- [63] LI D C, LI X, WANG J, et al. Video recommendation with multi-gate mixture of experts soft actor critic[C]//Proceedings of the 43rd International ACM Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 1553-1556.
- [64] 曹泽麟, 徐君, 董振华, 等. 基于多任务学习的位置倾向性得分预测算法[J]. 计算机研究与发展, 2023, 60(1): 85-94.
- CAO Z L, XU J, DONG Z H, et al. Prediction of the positional propensity scores based on multi task learning[J]. Journal of Computer Research and Development, 2023, 60(1): 85-94.
- [65] XU M W, CAI D Q, YIN W S, et al. Resource-efficient algorithms and systems of foundation models: a survey[J]. ACM Computing Surveys, 2025, 57(5): 1-39.
- [66] CAI W L, JIANG J Y, WANG F, et al. A survey on mixture of experts in large language models[J]. IEEE Transactions on Knowledge and Data Engineering, 2025, 37(7): 3896-3915.
- [67] 史宏志, 赵健, 赵雅倩, 等. 大模型时代的混合专家系统优化综述[J]. 计算机研究与发展, 2025, 62(5): 1164-1189.
- SHI H Z, ZHAO J, ZHAO Y Q, et al. Survey on system optimization for mixture of experts in the era of large models[J]. Journal of Computer Research and Development, 2025, 62(5): 1164-1189.
- [68] JOHNSON A, GONZALEZ M, KIM D, et al. Improving large language model performance through compression and optimization[EB/OL]. [2025-06-03]. https://d197for5662m48.cloudfront.net/documents/publicationstatus/250935/preprint_pdf/8c8f5de0a8701e3d19c6da6240ef12d3.pdf.
- [69] JI H S, SI Q Y, LIN Z, et al. Towards one-to-many visual question answering[C]//Findings of the Association for Computational Linguistics: EMNLP 2024, 2024: 16931-16943.
- [70] DU N, HUANG Y P, DAI A M, et al. GLaM: efficient scaling of language models with mixture-of-experts[C]//Proceedings of the 39th International Conference on Machine Learning, 2022: 5547-5569.
- [71] LANG J, HONG R P, XU J, et al. Biting off more than you can detect: retrieval-augmented multimodal experts for short video hate detection[C]//Proceedings of the ACM on Web Conference 2025. New York: ACM, 2025: 2763-2774.
- [72] LIU A X, FENG B, WANG B, et al. DeepSeek-V2: a strong, economical, and efficient mixture-of-experts language model[EB/OL]. [2025-06-07]. <https://arxiv.org/abs/2405.04434>.
- [73] SU J L, AHMED M, LU Y, et al. RoFormer: enhanced Transformer with rotary position embedding[J]. Neurocomputing, 2024, 568: 127063.
- [74] JI T, GUO B, WU Y B, et al. Towards economical inference: enabling DeepSeek's multi-head latent attention in any Transformer-based LLMs[EB/OL]. [2025-06-08]. <https://arxiv.org/abs/2502.14837>.
- [75] SHEN K, GUO J L, TAN X, et al. A study on ReLU and softmax in Transformer[EB/OL]. [2025-06-09]. <https://arxiv.org/abs/2302.06461>.
- [76] FILIPEK A. Sparse query attention (SQA): a computationally efficient attention mechanism with query heads reduction[EB/OL]. [2025-06-11]. <https://arxiv.org/abs/2510.01817>.
- [77] YANG M R, LI F X, XIAO T, et al. Multi-scale feature fusion using matrix decomposition for enhanced transformer performance on small-scale datasets[J]. Journal of Circuits, Systems and Computers, 2025, 34(12): 2550291.
- [78] HUANG Q Z, AN Z W, ZHUANG N, et al. Harder tasks need more experts: dynamic routing in MoE models[EB/OL]. [2025-06-13]. <https://arxiv.org/abs/2403.07652>.
- [79] BHATELE A, FEIZI S, HE S, et al. Loki: low-rank keys for efficient sparse attention[C]//Advances in Neural Information Processing Systems 37, 2024: 16692-16723.
- [80] ZHOU L Q, PENG X H, CHEN M, et al. Unveiling patterns in spatial transcriptomics data: a novel approach utilizing graph attention autoencoder and multiscale deep subspace clustering network[J]. GigaScience, 2025, 14: giae103.
- [81] KHANAM R, HUSSAIN M, HILL R, et al. A comprehensive review of convolutional neural networks for defect detection in industrial applications[J]. IEEE Access, 2024, 12: 94250-94295.
- [82] ZHANG R, MENG Q, ZHU R C, et al. Monte Carlo neural PDE solver for learning PDEs via probabilistic representation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, 47(6): 5059-5075.
- [83] MU S Y, LIN S. A comprehensive survey of mixture-of-experts: algorithms, theory, and applications[EB/OL]. [2025-06-18]. <https://arxiv.org/abs/2503.07137>.